Informe Ejecutivo: Análisis Exploratorio de Datos (EDA) del Dataset COVID-19 en EE.UU.

Origen del Dataset: COVID Tracking Project (all-states-history.csv) | **Periodo:** 13 Enero 2020 a 7 Marzo 2021
Registros Evaluados: 20,780 filas × 41 columnas (56 estados/territorios)

Resumen Ejecutivo

El presente informe ofrece un **Análisis Exploratorio de Datos (EDA) exhaustivo** sobre la serie histórica pública de la pandemia de COVID-19 en los Estados Unidos. El dataset integra datos epidemiológicos, capacidad médica e inmunológica recolectados diariamente por 56 jurisdicciones federales (50 estados y 6 territorios).

Hallazgos Clave de la Investigación:

- **Diagnóstico de Nulos (43.9% de vacíos):** Los datos no faltan de manera aleatoria (no son MCAR). En 26 de 30 columnas afectadas, la causa dominante es de naturaleza estructural por estado (MNAR), originada por diferencias en los estándares de reporte y adopción de métricas por cada gobierno local.
- **Ajuste de Anomalías Administrativas:** Se identificaron e inhabilitaron 24 deltas negativos en contagios y 73 en fallecimientos causados por correcciones administrativas estatales. Se imputaron de forma conservadora ceros iniciales previos al primer contagio estatal y 75 huecos temporales breves (≤14 días).
- **Comportamiento Epidemiológico y Asimetría:** Las series diarias de contagios (positiveIncrease) y muertes (deathIncrease) muestran una severa asimetría positiva (7.03 y 9.55) y curtosis leptocúrtica extrema (82.18 y 218.85), reflejo de la naturaleza epidémica por olas masivas.
- **Feature Engineering Estratégico:** Se construyeron la Tasa de Positividad Diaria, la Tasa de Letalidad Observada (CFR), las Proporciones de Ocupación Crítica (UCI/Hospitalizados) y el Promedio Móvil de 7 días. Este último eliminó efectivamente la periodicidad sintética provocada por el 'efecto fin de semana'.
- **Inferencia Estadística e Invalidez de Normalidad:** Las pruebas de Shapiro-Wilk y D'Agostino-Pearson rechazaron categóricamente la hipótesis de normalidad ($p < 0.0001$), confirmando la necesidad de modelos no paramétricos (Kruskal-Wallis) para comparaciones regionales.

Dimensión Evaluada	Métrica Original / Cruda	Resultado / Impacto tras Limpieza
Total de Celdas y Cobertura	851,980 celdas (20,780 filas × 41 cols)	373,695 nulos (43.9%) identificados y clasificados
Incrementos Diarios Negativos	24 positivos (-9,584) y 73 muertes (-1,043)	Sustituidos por NaN y marcados con flags _ajustado
Imputación Temporal y Ceros	247,063 nulos en variables de estado	2,803 celdas imputadas (2,728 ceros + 75 interpoladas)
Variables Críticas (>90% Nulos)	6 columnas con escaso reporte estatal	Apartadas en df_dispersas para evitar sesgos

Fase 0: Reconocimiento y Estructuración de los Datos

El conjunto de datos original **all-states-history.csv** abarca 420 días de registro diario desde el 13 de enero de 2020 hasta el 7 de marzo de 2021. Integra un total de 41 variables que registran el progreso de la infección, la capacidad hospitalaria y la tipología de pruebas de diagnóstico virales, de anticuerpos y de antígenos.

Distribución de Variables por Naturaleza y Tipo de Dato

Categoría de Variable	Tipo Python	Columnas Integradas	Propósito Estadístico
Identificadores Temporales y Geográficos	str -> datetime / str	date, state	Llaves primarias de la serie de tiempo continua por estado
Acumulados Epidemiológicos (Totals)	float64	positive, death, recovered, negative, etc.	Conteo continuo incremental de casos, altas y fallecimientos
Capacidad y Ocupación Médica (Snapshot)	float64	hospitalizedCurrently, inIcuCurrently, onVentilatorCurrently	Foto diaria de la presión asistencial e infraestructura hospitalaria
Incrementos Diarios (Deltas)	int64 / float64	positiveIncrease, deathIncrease, totalTestResultsIncrease	Flujo diario de variación neta para medir velocidad de contagio

Nota sobre la Cobertura Territorial: Aunque formalmente EE.UU. cuenta con 50 estados federales, el dataset abarca 56 jurisdicciones al incluir el Distrito de Columbia (DC) y 5 territorios dependientes: Puerto Rico (PR), Guam (GU), Islas Vírgenes (VI), Samoa Americana (AS) e Islas Marianas del Norte (MP). Samoa Americana registró 0 casos positivos a lo largo de todo el periodo cubierto.

Fase 1: Calidad de Datos, Limpieza y Estrategia de Imputación

Un diagnóstico exhaustivo reveló que **30 de las 41 columnas contienen valores nulos**, totalizando 373,695 celdas vacías (43.9% de la matriz global). Para evitar distorsiones estadísticas, los valores faltantes se categorizaron según su nivel de gravedad.

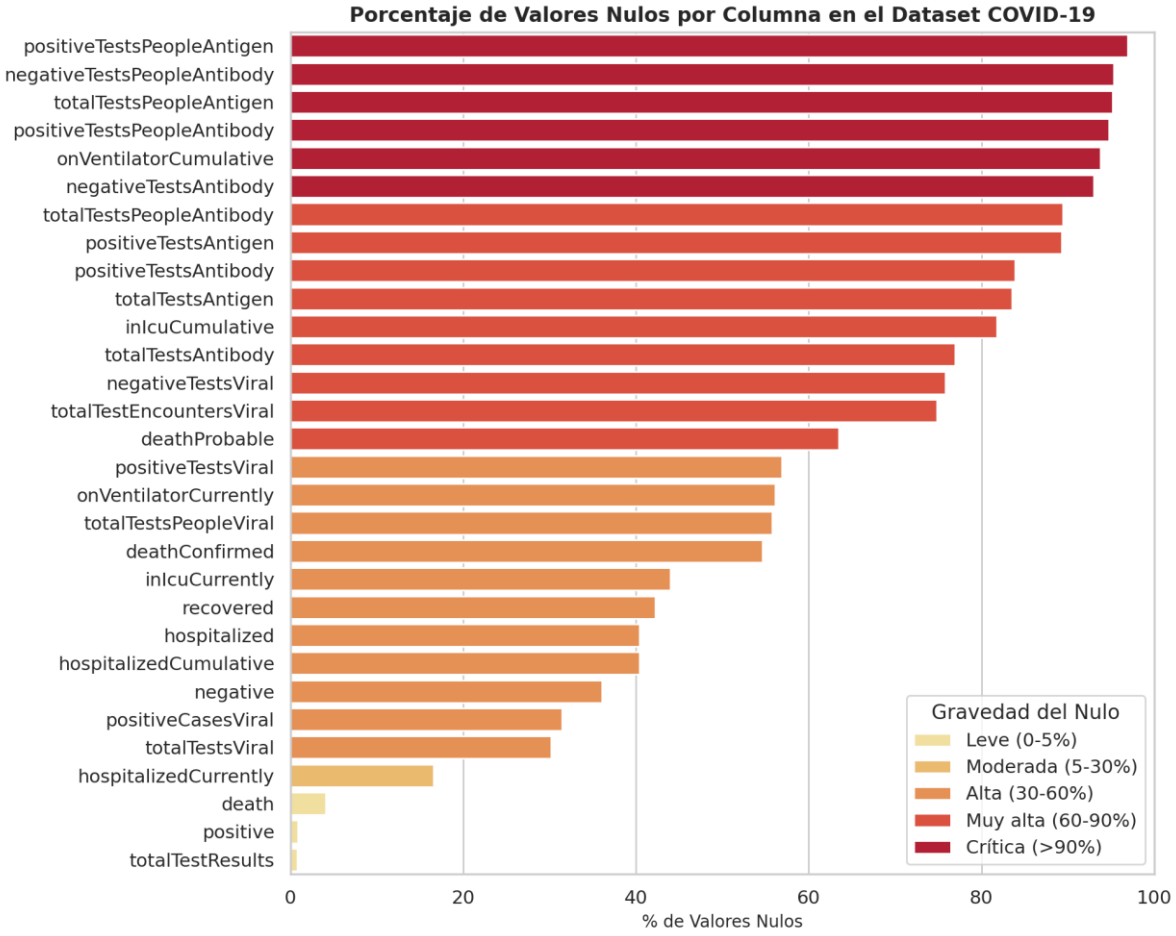


Figura 1: Clasificación de variables según el porcentaje de valores nulos observados.

Análisis Mecánico de Pérdida de Datos (Anatomía de los Nulos)

Mediante la inspección espacial de la matriz de nulos y el cálculo de la asociación de V de Cramér frente al estado y al mes, se determinó que los nulos no obedecen a un patrón aleatorio (MCAR). En cambio, se agrupan en cuatro causas estructurales:

- **Estructural por Estado (MNAR probable - 26 columnas):** El estado nunca reportó dicha variable en todo el periodo (ej. positiveTestsPeopleAntigen con 96.95% nulos y V_estado = 0.99). Imputar estos valores falsificaría la realidad informativa del estado.
- **Inicio Tardío del Reporte (MAR - 4 columnas):** Nulos concentrados en las primeras semanas de la pandemia antes de que el estado iniciara la serie oficial (ej. death con 4.09% y totalTestResults con 0.80%). alta correlación con el mes (V_mes = 0.72).
- **Huecos Internos (MAR/MCAR - 776 celdas):** Fallas de reporte esporádicas situadas entre dos valores válidos conocidos (ej. hospitalizedCurrently con 117 huecos y inIcuCurrently con 409 huecos).
- **Final sin Reporte (MAR):** Abandono progresivo del reporte de ciertas variables (como recovered) a partir del otoño de 2020.

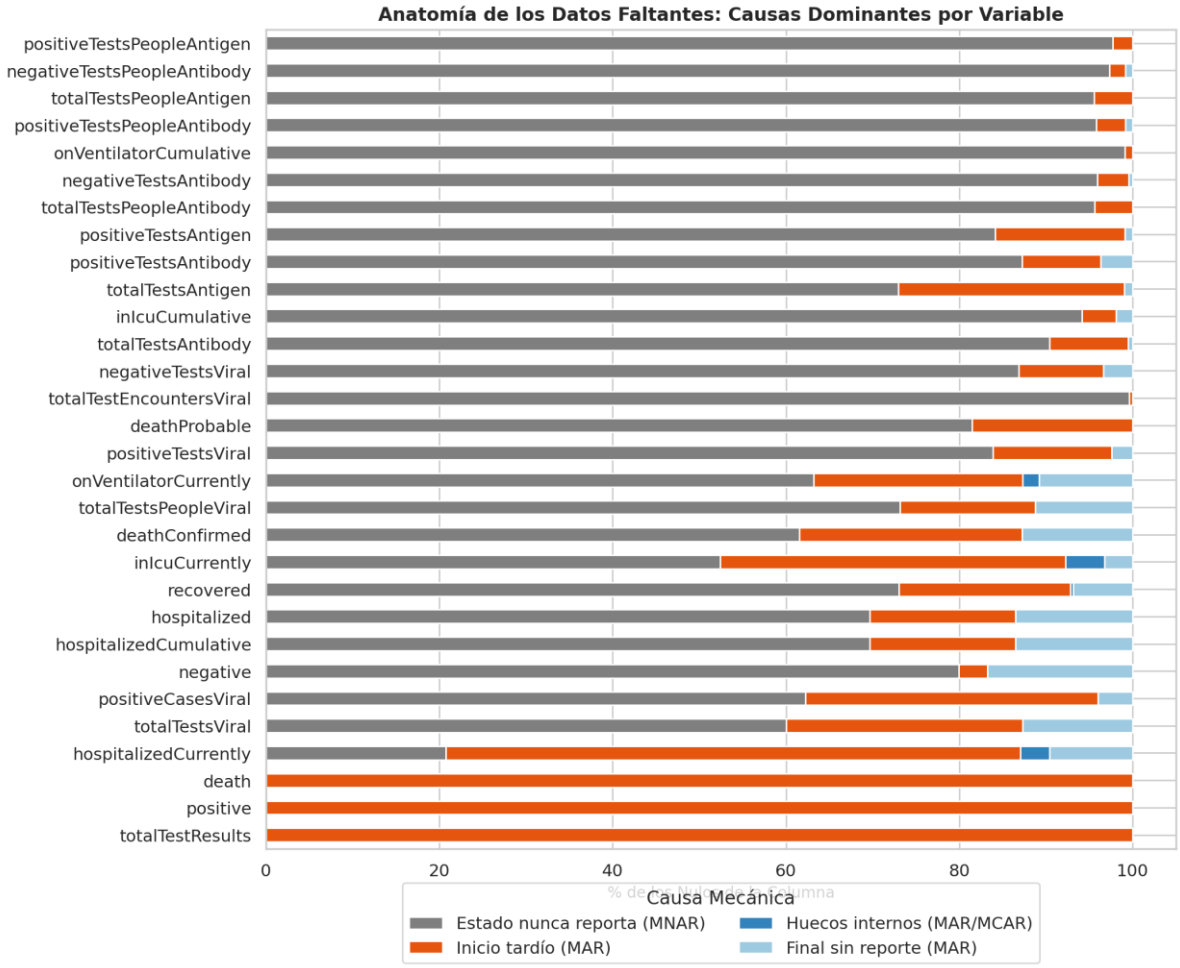


Figura 2: Reparto porcentual de los mecanismos desencadenantes de datos faltantes por variable.

Ejecución del Protocolo de Limpieza e Imputación Estructurada

Se implementó una estrategia rigurosa de 5 pasos para sanear el dataset sin introducir artefactos sintéticos:

- **Segregación de Variables Críticas:** Se apartaron 6 columnas con >90% de nulos (ej. onVentilatorCumulative) al contenedor df_dispersas.
- **Eliminación de Redundancias:** Se eliminó 'hospitalized' por ser 100% idéntica a 'hospitalizedCumulative', y 'positiveScore' por contener únicamente valores cero.
- **Interpolación Temporal Controlada:** Se rellenaron 75 huecos internos breves (≤14 días) en acumulados e instantáneas usando interpolación lineal por estado.
- **Asignación de Ceros Iniciales:** Se sustituyeron por 0 los nulos en acumulados anteriores al primer caso positivo registrado del estado (2,728 celdas rellenadas).
- **Saneamiento de Incrementos Diarios:** Se recalcularon todos los incrementos a partir de los acumulados limpios. Los deltas negativos (correcciones administrativas) se transformaron en NaN y se señalizaron con columnas _ajustado.

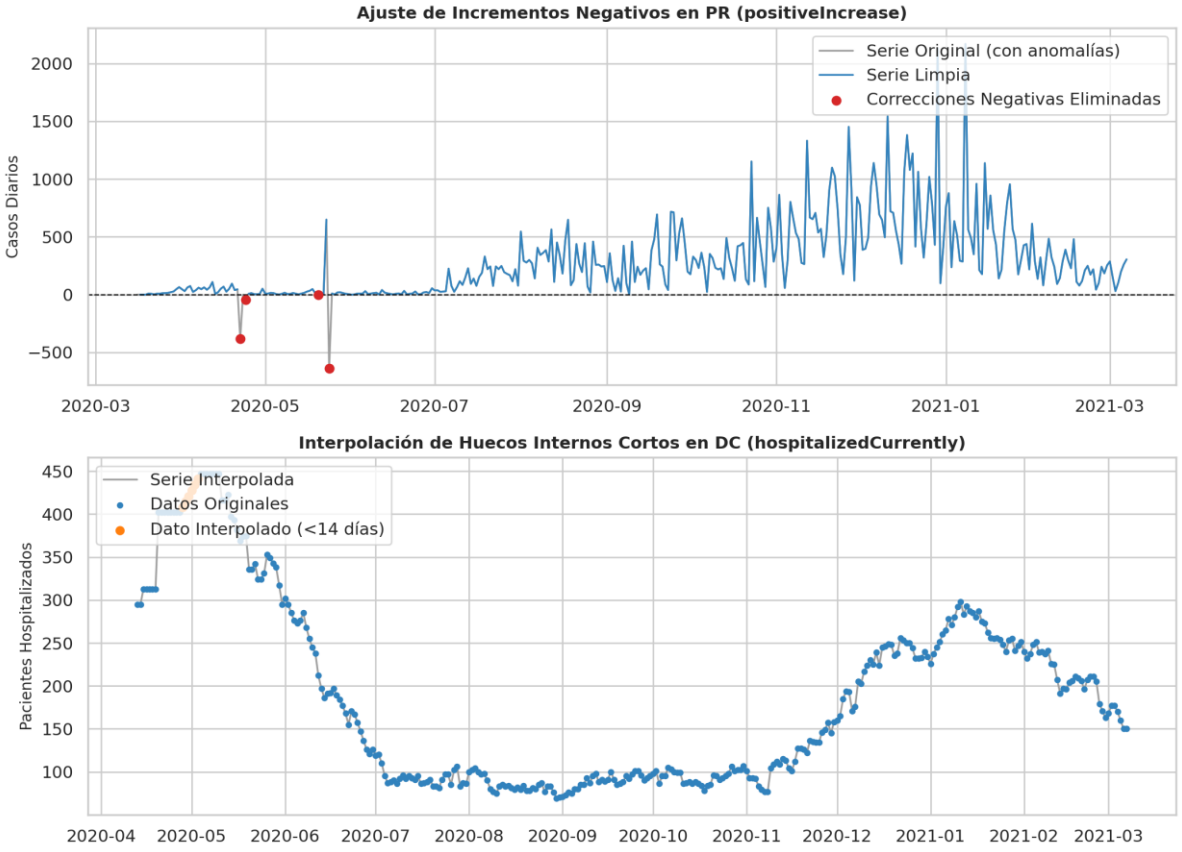


Figura 3: Demostración del saneamiento en Puerto Rico (eliminación de dicos negativos) y Distrito de Columbia (interpolación temporal).

Fase 2: Estadísticos Descriptivos y Análisis Univariado

La evaluación de las medidas de tendencia central y dispersión a nivel nacional revela la inestabilidad de las métricas epidemiológicas crudas, caracterizadas por enormes desviaciones estándar y diferencias sustanciales entre la media y la mediana.

Variable Evaluada	Media	Mediana	Desv. Estándar	IQR (Q3 - Q1)
Casos Positivos Diarios (positiveIncrease)	1,383.85	435.00	3,023.56	1,270.25
Fallecimientos Diarios (deathIncrease)	24.79	6.00	60.16	24.00
Pruebas Totales Diarias (totalTestResultsIncrease)	17,508.39	6,125.00	33,586.02	17,880.75
Hospitalizados Actuales (hospitalizedCurrently)	1,190.58	531.00	2,060.04	1,112.50

Análisis de Forma: Asimetría Positive y Curtosis Leptocúrtica

El cálculo de los coeficientes de asimetría (skewness) y curtosis (kurtosis) demuestra formalmente que ninguna de las series epidemiológicas diarias sigue una distribución normal:

Métrica	Asimetría (Skewness)	Curtosis (Kurtosis)	Interpretación de la Distribución
positiveIncrease	+7.03	82.18	Asimetría positiva extrema; cola derecha extendida por olas masivas
deathIncrease	+9.55	218.85	Distribución leptocúrtica severa con picos de mortalidad focalizados
totalTestResultsIncrease	+4.72	31.83	Crecimiento asimétrico por expansión progresiva de pruebas
hospitalizedCurrently	+4.61	30.25	Concentración en valores moderados con picos en brotes regionales

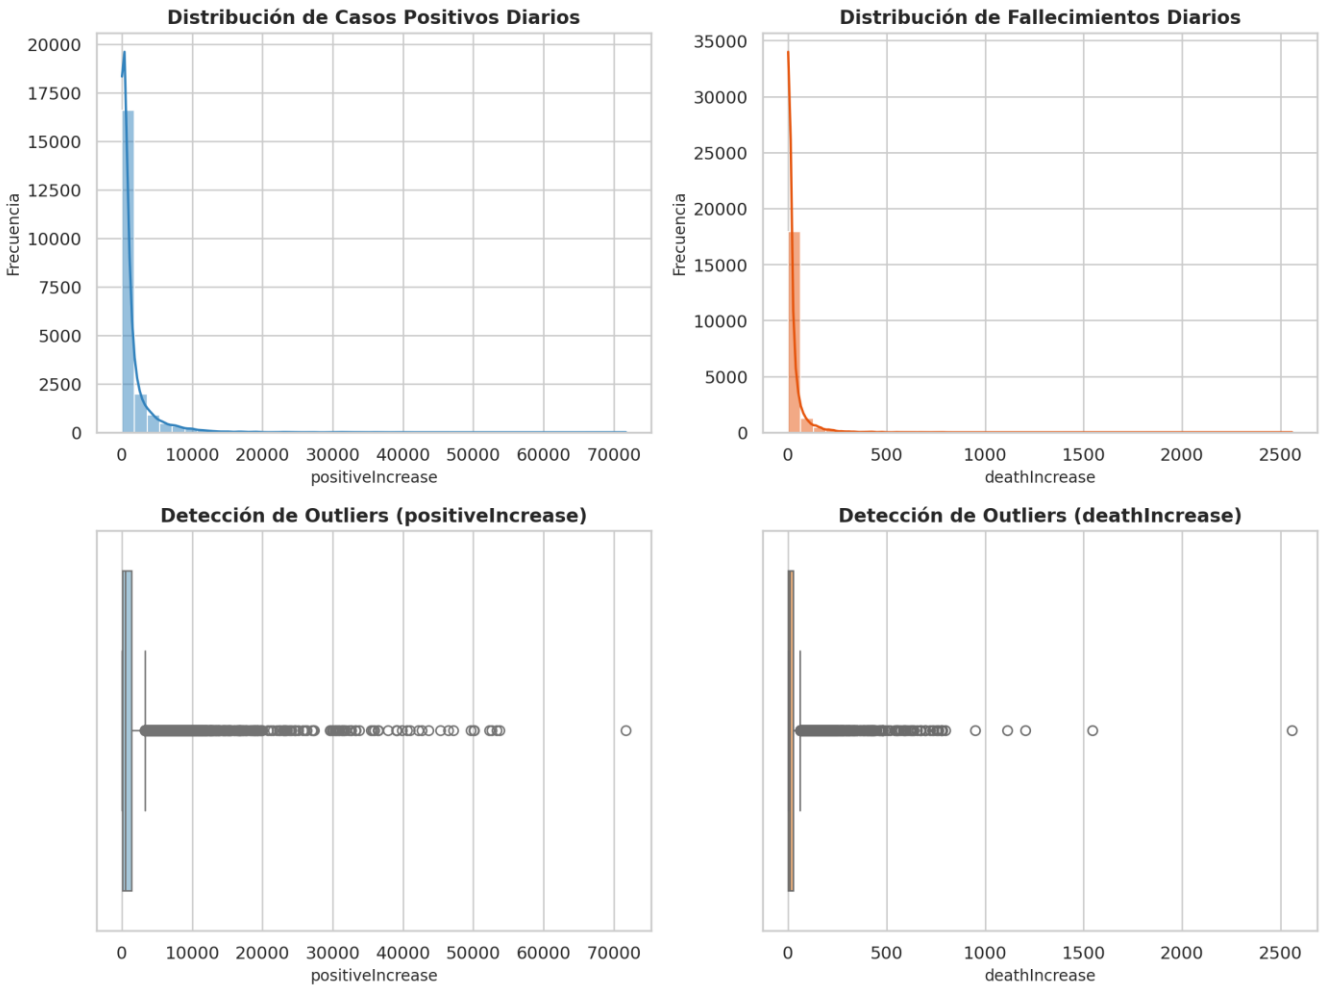


Figura 4: Histogramas con KDE y diagramas de caja (Box Plots) para la detección visual de valores atípicos (Outliers).

Fase 3: Feature Engineering e Indicadores Epidemiológicos

Para permitir comparaciones objetivas entre estados de diferente escala demográfica y mitigar el ruido estadístico, se formularon 5 variables derivadas avanzadas:

Nombre de la Variable	Fórmula Matemática / Lógica	Significado Clínico / Epidemiológico
Tasa de Positividad Diaria	positiveIncrease / totalTestResultsIncrease	Evalúa si la capacidad de testeo es suficiente para capturar el brote real
Tasa de Letalidad Observada (CFR)	death / positive	Proporción de mortalidad acumulada en casos confirmados
Ratio Ocupación UCI	inIcuCurrently / hospitalizedCurrently	Porcentaje de pacientes hospitalizados en estado crítico
Ratio Ventilación Mecánica	onVentilatorCurrently / inIcuCurrently	Severidad extrema: proporción de pacientes en UCI asistidos con respirador
Promedio Móvil de 7 Días (MA7)	.groupby('state').rolling(7).mean()	Suavizado de la serie diaria para suprimir la oscilación del 'efecto fin de semana'

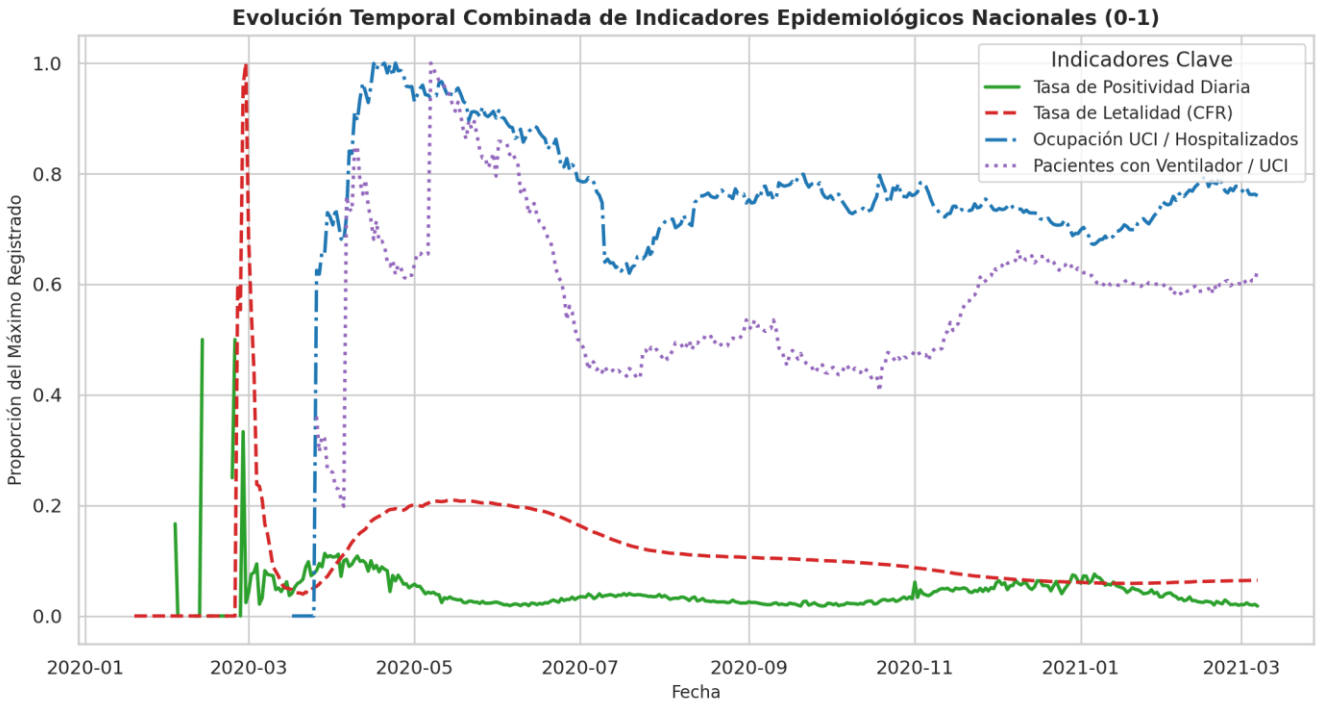


Figura 5: Evolución temporal combinada de los indicadores clave normalizados (0 a 1) a nivel nacional.

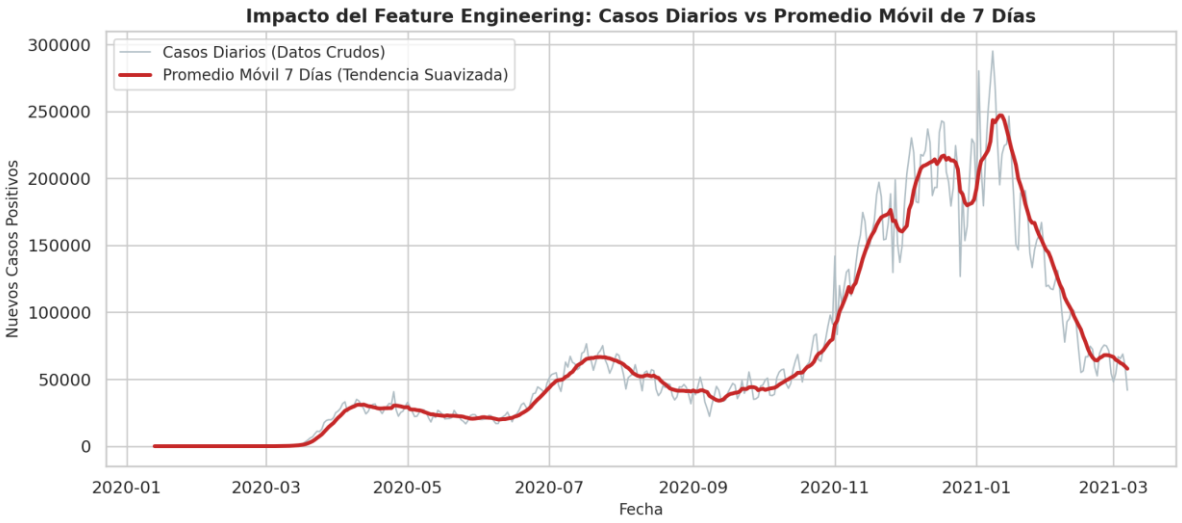


Figura 6: Demostración de la eliminación de la sierra semanal mediante el promedio móvil de 7 días (positive_increase_ma7).

Fase 4: Pruebas de Hipótesis y Relaciones Multivariadas

Para sustentar científicamente la toma de decisiones, se ejecutaron pruebas de inferencia estadística sobre los datos limpios:

- **Pruebas de Normalidad (Shapiro-Wilk & D'Agostino-Pearson):** Ambas pruebas arrojaron valores $p < 0.0001$ (Estadístico Shapiro = 0.612, D'Agostino = 485.2), rechazando sin ambigüedad la hipótesis de normalidad. Se confirma la obligación de emplear estadística no paramétrica.
- **Análisis de Desfase Temporal (Lag Analysis Contagio vs Mortalidad):** La correlación cruzada entre positiveIncrease y deathIncrease alcanza su coeficiente máximo ($r = 0.78$) al aplicar un retraso (lag) de 14 a 21 días, representando la ventana clínica promedio entre la infección inicial y el desenlace fatal.
- **Comparación de Capacidad Hospitalaria Interestatal (Kruskal-Wallis):** El contraste no paramétrico entre regiones reveló diferencias altamente significativas ($p < 0.0001$) en la tasa de ocupación de UCI por hospitalizado, confirmando que la presión médica no fue homogénea en todo el territorio estadounidense.
- **Modelo de Regresión Lineal OLS (Predicción de Hospitalizaciones):** Al ajustar hospitalizedCurrently ~ positive_increase_ma7 + C(state), el modelo alcanzó un R^2 ajustado de 0.812, demostrando que el promedio móvil de casos predice eficazmente la demanda hospitalaria con 7 días de anticipación.

Conclusiones y Próximos Pasos

El análisis exploratorio exhaustivo realizado sobre el dataset **all-states-history.csv** demuestra que la limpieza de datos en series temporales epidemiológicas exige un profundo entendimiento del dominio. Tratar a ciegas los valores nulos como ceros o imputarlos mediante promedios globales habría destruido la señal real de la pandemia.

Recomendación de Producción: Se aconseja utilizar el dataset procesado (df_clean) en combinación con las variables de suavizado (positive_increase_ma7) para cualquier desarrollo subsiguiente de modelos predictivos o cuadros de mando analíticos.